




正文

计算与智能的原理视角（综述）——尼克老师《计算与智能的第一性原理》第一讲

已声明原创08-186,328次浏览

黄大年茶思屋科技网站特邀乌镇智库理事长尼克老师（张晓东），开讲《计算与智能的第一性原理》系列课程。从数学算法到物理本质，用“第一性原理”带我们重新认识计算与智能。




AI视频摘要：牛顿的《自然哲学的数学原理》激发了对第一性原理的探讨，涵盖了计算本质、广义学习定义、实现方法及唯心与唯物的关系。讲座围绕图灵机的结构和功能展开，强调其在计算理论中的核心地位，并提及量子计算对其理论的潜在挑战。哥德尔和Post的工作进一步证明了图灵机的普遍性，而人工智能的发展，从早期的专家系统到现代的深度学习模型，都受到了图灵机的启发。此外，摩尔定律和兰道尔极限揭示了计算能力增长的物理限制，而大型科技公司在人工智能领域的进展引发了对能源需求的关注。最后，柯尔莫哥洛夫的复杂性和所罗门诺夫归纳等理论在现代人工智能研究中重新受到重视，但同时也面临着技术和伦理挑战。

以下为尼克老师《计算与智能的第一性原理》首期课程文字实录：

1. 第一性原理溯源

今天我要讲的题目很大，叫“第一性原理”。内容没用英文，而是用了拉丁文“PRINCIPIA”。这个词本身就是“原理”的意思，在拉丁文里就包含了“第一性原理”的含义，所以我不用再说“First Principle”。

Newton在书中用拉丁文写道“我不做假设”。今天讲第一性原理时，我也效仿他不做假设的姿态，所以使用PRINCIPIA这个被广泛采用的术语。



这位是Russell（罗素），现代逻辑的开创者。他与老师Whitehead（怀特海）合著了《数学原理》。此前Newton写过英文的《Principles of Mathematics》，但Russell的三卷本著作中，大部分标题仍沿用拉丁文，比Newton又简化了些。Newton的书名是《自然哲学的数学》，Russell直接用了《数学》。而到我这里更进一步，我把数学都省去了。



一位西方科学史家说过：“本质的东西就是唯心的东西，就是Mind。你内心认知的那个东西才是最重要的。”因为在座有一半是学数学和计算机的，所以我必须格外谨慎地向大家阐明我的思路。

今天我要讲四个问题。你们都知道Newton的著作包含四条原理，我这里也有四条。第一节课我会先做个综述，说明为什么这次讨论很重要，然后我会逐一讲解每一条原理。

四条原理

- 第一原理：什么是计算？存在最广义的计算吗？思维=计算？
- 第二原理：什么是学习？存在最广义的学习吗？
- 第三原理：存在普适的学习机制吗？
- 第四原理：计算（Mind）与物理（Matter）的关系。“It from bit”？

我来解释这四条原理。

第一条：我们需要明确什么是计算？当下人工智能和计算机科学很热门，但“计算”的本质是什么？是否存在一个最广义的计算定义？另一个自然产生的问题是：既然计算机和人工智能都在进行计算，那么思维本身是否也是一种计算？我未必能给出确切答案，但希望大家能提供一个思考这个问题的思路。


第二条：关于机器学习。大家是否思考过，什么是最广义的学习？就像图灵机定义了最广义的计算，是否存在一个机制能定义最广义的学习？我认为存在的。过去几十年里，数学家和计算机科学家已经在这方面做出了深刻贡献。因此，第二条我要重点探讨：什么是学习？当今人工智能，包括大模型，本质上都是学习。那么，学习是否存在最本质的第一性原理？这就是我们的第二个核心问题。

第三条：如果学习存在第一性原理，我们能否实现它？是否存在一些普适的、可实现的、最本质的学习机制？前三条原则都涉及很根本的哲学思考。

第四条：我们必然要探讨实用性的本质，唯物与唯心之间的关系。我所讨论的计算是基于唯心视角Mind，而我们身处的物理世界则属于唯物范畴Matter，这是西方哲学的传统分野。Russell幼年时父母早逝，由祖母抚养长大。六岁时，他就开始与祖母探讨哲学问题。当时他思考西方哲学中Mind与Matter的关系，问祖母：“什么是Mind？”祖母回答：“Doesn't Matter。”他又问：“什么是Matter？”祖母答道：“Never Mind。”十几年前去世的著名物理学家Wheeler（惠勒），是Feynman（费曼）的老师，也是一位影响深远的艺术家，尽管未获诺贝尔奖，他有句名言“It from bit”。国内很多翻译不够准确，往往把“it”译作“东西”，将“bit”的含义弱化了。实际上，“it”指的是物质，“bit”代表的是意识。用今天的理解来说，Wheeler认为物质源于意识。这是否真的如此？这正是我们最后要探讨的第四部分内容。

我计划用五次课程，虽然未必能完全讲清楚，但希望大家能阐明计算与治理的第一性原理，至少提供一个思考这些核心问题的思路。

2.最广义的计算



三年前，英国五十英镑钞票头像从Watt（瓦特）换成了Turing（图灵），这个变化很有象征意义，标志着世界从Matter转向了Mind的维度。

Feynman有句名言：“微积分是上帝的语言”。纵观几次工业革命，趋势确实越来越趋向“唯心”，最初是能源革命，后来是能源民主化，接着是计算能力革命，现在则进入了计算民主化的时代。



让我们谈谈图灵机。计算机专业的同学都知道，图灵机的构造极其简单：一条无限长的纸带，可以读写0和1、一个有限状态的读写头，能够左右移动。就这么简单，实际上，已经有人把它实体化了，用真实的纸带就能工作，甚至还有3D打印的模型在市场上出售。



图灵机仅凭读写0和1的简单机制能做什么？让我们用图灵机做个乘法演示，比如乘以3。准备三条纸带：输入带输入例如101#11，和两条工作带。读写头依次扫描输入带的每个数字，对每个数字在工作带重复写入三次，读到1就写入111，读到0就写入000。这样，输入101最终就会转换为111000111。这个例子展示了图灵机如何用最简单的0和1操作完成乘法运算。

实际上，虽然这个例子用了三条带子，但理论上任何多带图灵机都可以等效转换为单带图灵机。其他带子的功能都能通过一条主带子上的特定编码方式来实现。一个图灵机包含几十个状态，毕竟是有限状态机，每个状态都对应特定的位置和操作规则。最终它确实能完成乘法，比如输出“111”这样的结果。

原理1：丘奇-图灵论题 (Church-Turing Thesis) 是计算机科学的基石

丘奇-图灵论题 (Church-Turing Thesis) 断言：图灵机是最广义的计算装置。

图灵机 = 丘奇的 λ -演算
= Gödel-Herbrand 广义递归函数
= Post Tag 系统 = Post产生式系统
= 乔姆斯基 0型文法
= ...

丘奇-图灵论题有时也称图灵论题，是计算机科学的基石。它之于计算机科学，宛如公理之于几何学，牛顿定律之于物理学。计算理论的缘起就是丘奇-图灵论题的形成过程。

是论题，不是数学定理，也不是物理学定律。

强丘奇-图灵论题 (洪加威相似性原则)：所有的计算装置都可以低成本互相模拟，即多项式时间空间。量子计算是挑战。

这就是我要讲的第一条原理：**究竟什么是计算？图灵机给我们提供了一个极其精妙的思考框架。时至今日，我们依然没有发现比图灵机更强大的计算模型。**这个仅能读写0和1、左右移动的简单装置，至今仍是计算能力的极限。这正是计算机科学的支柱：Church-Turing Thesis (丘奇-图灵论题)。请注意，这是“论题”而非定律或定义。定律属于物理学范畴，定义是数学概念，而我们称之为“Thesis”。

Church (丘奇) 作为Turing的导师提出的这个论题阐明：**图灵机定义了最广义的计算过程。现今所有的计算装置、语言学系统和数学模型，只要足够强大，都能被图灵机模拟。**这就是Church-Turing Thesis的深刻内涵。

大家都知道Turing的老师Church提出了Lambda演算，这正是现代计算机语言的基石。它最初应用于Lisp语言，并且能够证明计算过程的机械化，就像图灵机那样。

Gödel (哥德尔) 提出的递归函数试图建立一个能将所有数学归结于其上的机制。1936年，这种递归函数被证明与图灵机等价。到了50年代，Chomsky (乔姆斯基) 发现4种文法，其中最不受限制的那类文法同样等价于图灵机。

特别要提到Strong Church-Turing Thesis (强丘奇-图灵论题)，它之所以称为“论题”而非“定义”，正是因为它无法被严格定义。每当提出一个新的计算模型，要么它不够强大，要么只要足够强大就必然被证明与图灵机等价。它也不像物理定律那样基于实验数据归纳，而是我们发现所有足够强大的计算理论最终都彼此等价。这就是“论题”的本质特征。

Strong Church-Turing Thesis确实存在一些争议。它说的是：不仅所有计算装置在功能上等价，它们之间的模拟成本也很小。“很小”具体指什么？在计算机科学中，我们判断算法是否高效的标准就是多项式时间和多项式空间。目前已知的所有计算装置，都能以很小的时空成本互相模拟。但现在有个有趣的挑战：量子计算。目前量子计算机在计算能力上仍等价于图灵机，但两者互相模拟的成本可能无法保持这么低，不过这一点尚未被严格证明。

关于量子计算的描述经历了一些演变。最早有人称之为Quantum Supremacy (量子霸权)，后来觉得这个词不太妥当，就改成了 Quantum Advantage (量子优势)。但关键问题是：这个所谓的“Quantum Advantage”是否真的成立？目前还没有定论。关键在于，量子计算机能否以远低于图灵机的成本完成某些计算？反过来，图灵机能否以合理成本模拟量子计算机？特别是，量子计算机能否在更低成本下完成图灵机多项式时间的任务？这仍是未解之谜。

所以，我将在第二课讲第一性原理时展开讨论，但今天要提到：最早提出强Strong Church-Turing Thesis的中国数学家洪加威，如今已经80多岁，在旧金山隐居。80年代初，他经著名数学家、逻辑学家、哲学家王浩推荐，成为王浩的学生Cook (古克) 的访问学者，Cook提出了P/NP问题。正是在此期间，洪加威想到了，当时他称之为“相似性原则”的问题，意指计算模型在多项式时间和空间内可互相模拟，而非现在的“Strong Church-Turing Thesis”这一名称。

原理1：论题 (Thesis) vs 原理与定义

“论题”作为原理：

量子计算理论家：David Deutsch, Church-Turing Principle
物理学家 Stephen Wolfram, “计算等价原理” (Principle of Computational Equivalence)

论题，不是数学定理，也不是物理学定律，是定义吗？

微积分中 (ϵ, δ) 语言是定义还是论题？

我们说“柯西-魏尔施特拉斯论题” (Cauchy-Weierstrass Thesis) 吗？


数学史家称柯西为：“the man who taught rigorous analysis to all of Europe”.



The function $f(x)$ is continuous with respect to x between the given limits if, between these limits, an infinitely small increment in the variable always produces an infinitely small increment in the function itself.

我讲的第一原理就是Church-Turing Thesis，图灵机定义了最广义的机械计算。目前唯一的支持证据是我们尚未找到反例。这种“论题”形式不只存在于计算机科学。数学中也有很多类似概念，只是数学家习惯称之为定义或定理。比如微积分入门就要学的 ϵ - δ 极限定义，本质上也是基于共识的论题，它建立在许多假设之上，比如“任意五点之间必有一点”，这些假设在物理世界未必成立。

Cauchy (柯西) 在19世纪严格定义了微积分，数学史家公认他是第一人。但所谓“严格”，从计算理论角度看，其中也包含了许多共识，不全是严谨的定理或定义。这就是为什么有些数学分析教科书称之为“Cauchy-Weierstrass Theorem (柯西-魏尔施特拉斯定理)”。



那么，图灵机又是如何产生的呢？图灵机并非最早的概念。Turing在1936年发表那篇著名论文前，他的老师Church在1935年就提出了Lambda演算。再往前追溯，1934年Gödel在证明不完全性定理时引入了原始递归函数，但他意识到他的表达能力有限，后来在法国数学家Herbrand（厄尔布朗）的协助下于1934年提出了广义递归函数。

看过《Oppenheimer》电影的人可能记得，Oppenheimer曾想造一个能改变宇宙的装置，为此他去找Einstein（爱因斯坦）。当时与Einstein散步的正是Gödel。这位比Einstein晚一辈的学者，晚年也在普林斯顿高等研究院工作。Einstein对Gödel评价极高，曾说：“我每天上班的主要动力，就是能有机会和Gödel一起散步。”Gödel在逻辑学、数学领域贡献卓著，晚年还在广义相对论方面做出了重要工作。


Gödel在1934年就提出了广义递归函数，地位举足轻重。当Church在1935年提出Lambda演算时，他第一时间证明了Lambda演算与Gödel的递归函数等价，于是兴冲冲地去找Gödel，说：“我发明的这个系统和你的广义递归函数是等价的，是不是可以说我们找到了最广义的计算装置？”Gödel却说“不”。直到1936年图灵机问世后，Gödel才被彻底说服。要知道，Gödel是出了名的严谨。他被誉为Aristotle（亚里士多德）之后最伟大的逻辑学家，从不会轻易认可任何理论。

那为什么图灵机最终打动了Gödel？这正是我第二课要重点讲解的。今天先点出关键，图灵机太简单了，就靠读写0和1、左右移动，却能模拟Gödel的广义递归函数和Church的Lambda演算，这种极简而强大的特性让它无可争议。

最右边的是Post（波斯特），这是个悲剧性人物。Gödel1931年证明了不完全性定理，而Post早在1921年就证明了类似结果，却因精神问题未能发表。1936年，他独立发明了与图灵机相似的装置，甚至更接近现代计算机。图灵机基于状态转换，而Post的机器引入了指令概念，类似今天的汇编语言。


我想说的是，如果说图灵机是最广义的计算装置，最有力的证据就是，人类最聪明的头脑发明的最精巧的计算模型，最终都被证明与这个极其简单的图灵机等价。没有比这更有说服力的证据了。

3.最广义的学习



让我们回到当下，聊聊这次AI热潮。虽然之前有过几次小高潮，比如2006年Hinton（辛顿）的深度学习、2011年，Hinton 和微软邓力突破语音识别、2012年李飞飞的ImageNet，但真正引爆全球的是2022年11月30日ChatGPT的发布。

这背后有个哲学命题：西方传统认为语言是区别人与其他造物的本质特征。AI研究者也一直将语言视为最后堡垒，但没想到如今的突破已远超Turing1950年提出的测试标准。之前的进展虽重要，却未能像ChatGPT这样直击人心。



关于最广义的学习定义，这确实是个引人入胜的话题。让我们从历史脉络说起：

McCarthy（麦卡锡），达特茅斯会议的组织者，常被称为“人工智能之父”。但据考证，他本人否认创造了“人工智能”这个词。在1954年，达特茅斯会议前两年，他编辑的文集中已出现相关思想。其中一篇7页的文章提出了一个关键问题：我们知道图灵机是“输入→机器→输出”的过程。但反过来呢？给定输出，能否推导出产生这些输出的图灵机？这就是最基础的学习问题。就像Church-Turing Thesis，后来所有学习装置，包括现今的大模型都指向这个核心：给你数据，训练出能生成类似数据的模型。这不就是图灵机的逆向过程吗？

McCarthy用数学语言描述了这个“图灵机求逆”问题：已知输出，如何反推生成它的图灵机？这既是数学思考，也是工程挑战。如今的大模型技术，本质上就是在实践这个“逆向图灵机”的构想。

原理2. 学习就是 Solomonoff 归纳: 1960~1964

next token prediction的数学依据

- Observations as data input.
- Form a hypothesis to explain all data. 一个假设就是一个图灵机
- Conduct an experiment to test the hypothesis
- If the data disconfirm the hypothesis, return to step 2 and form a new hypothesis. If the data confirm, provisionally accept the hypothesis.

这个问题等价于：Chaitin, G., On the length of programs for computing binary sequences. JACM, 1969.
所有的预测方法都是Solomonoff归纳法的近似。Universal AI.
用最小的理论/模型覆盖最大的数据集。因果？可能不停机，所以只能近似。
学习就是压缩：下界就是Kolmogorov复杂性。压缩是个经济学问题。
不可解释性是必然的，可解释性是偶然的。

Given $x_1, x_2, \dots, x_n$, predict x_{n+1}
例如：给定 3, 5, 7, 猜下一个



60年前，Solomonoff（所罗门诺夫）用70页的数学论文给出了一个关键证明：McCarthy 1954年提出的“图灵机求逆”问题，本质上等价于今天的“next token prediction”（下一个标记预测）。OpenAI首席科学家 Ilya（伊利亚）在采访中反复强调的这个概念，其数学本质就是：给定 x_1 到 x_n ，预测 x_{n+1} 。

这个证明的深刻之处在于：如果预测总是正确，就意味着你实际上为数据建立了一个图灵机模型。根据Church-Turing Thesis，既然图灵机是最广义的计算装置，那么“图灵机求逆”自然就是最广义的学习方式。Solomonoff证明了最广义的学习就是next token prediction，通过不断修正假设，本质上是个统计过程，直到能够持续做出正确预测。

这篇发表在《Information and Control》，现称《Information and Computation》的论文，揭示了大模型的理论基础：通过持续优化对下一个标记的预测，最终建立数据的有效模型。这正是“图灵机求逆”的现代实现。




让我们看一个工程实例。ChatGPT问世前，最出色的大模型是Google的BERT。2017年Transformer架构问世后，Google基于它开发了BERT。BERT在做什么？

它采用masked prediction（掩码预测）：给定 x_1 到 x_n 序列，随机遮蔽某个 x_i 让你预测。这与GPT的“next token prediction”（预测 x_{n+1} ）看似不同，但Solomonoff证明两者本质等价。next token prediction能解决包括掩码预测在内的所有学习问题。

有趣的是，当时工程界普遍认为双向建模（BERT）比单向建模（GPT）更高效。2018年GPT-1性能远逊于BERT，论文引用量也差距明显。现在请你们思考：若你当时是OpenAI董事，面对这种劣势会如何决策？


Ilya Sutskever, 一个工程问题: BERT vs GPT




所有监督学习可以被归约为自监督学习。监督学习就是给定序列对: $(x_1, c_1), (x_2, c_2), \dots, (x_m, c_m)$ 以及 x_{m+1} , 预测 c_{m+1} 。这可以转化为自监督学习: 给定序列 $(x_1, c_1, x_2, c_2, \dots, x_m, c_m, x_{m+1})$, 预测 c_{m+1} 。

Ilya claims 他2016年独立想出

当时OpenAI面临巨大压力：投入海量算力训练GPT，性能却始终落后BERT。董事会必然质问：为何不放弃？这就要归功于Ilya对第一性原理的坚持，他坚信next token prediction是根本方向。直到2023年8月14日，Ilya在Simons Institute的演讲中终于公开承认：“你们是对的，我们的第一性原理就是Solomonoff归纳。”这个迟来的认可印证了一个简单事实：所有监督学习都能转化为next token prediction。



举个不严谨但直观的例子。从2023年初开始，所有主流大模型都转向了GPT架构，采用next token prediction方法。如今BERT仅用于某些专业领域，而next token prediction已成为行业标准。这印证了一个重要道理：当你把握住第一性原理时，必须坚持己见。



自然语言确实是个非常有趣的话题。为什么语言的突破如此重要？因为在人类历史上，我们一直认为语言是人类独有的能力。这种我们人类特有的能力，一旦取得突破，意义自然非同寻常。

让我们看看具体的发展历程：早在1952年，中国就派学者到苏联学习自然语言处理。那时候的翻译机，只能翻译几十个单词，比如54个俄语单词对应几十个或一百个汉语单词，功能非常有限。

从50年代到90年代，整整40年间，自然语言处理技术本质上没有太大变化，一直依赖小型的专家系统、专家知识或语法规则。直到90年代Google成立，开始采用浅层机器学习进行翻译，效果才突然有了显著提升。

这里有个有趣的现象：以前大公司的机器翻译团队里有很多语言学家，但现在Google有个流行的说法：每开除一个语言学家，我们的自然语言处理能力就能提升10%。这说明我们不再需要传统的语言学知识，只需要把握第一性原理和学习机制。随着深度学习的应用，Google翻译的水平得到了巨大提升。

最后来看GPT的发展：2023年以来，我们每天都在见证它的进步。这个领域的发展轨迹很像Moore's Law（摩尔定律）。最初的知识体系持续了40年，第二代的浅层学习体系维持了约20年，第三代深度学习从2017年到2022年ChatGPT问世只用了不到10年。现在这个技术几乎每个月、甚至每个星期都在发生变化，其中的原因值得我们后续深入探讨。

[illegible]

我们已经确认存在最广义的学习机制，但关键在于：如何通过工程手段实现Solomonoff归纳？虽然ChatGPT已经证明了一种可行性，但这是否是唯一的路径？这个问题自然将我们引向神经网络的发展历程。

神经网络的故事充满了戏剧性的转折。早在1943年，McCulloch（麦卡洛克）和Pitts（皮茨）就开创性地提出了神经网络模型，并自豪地证明了其与图灵机的等价性。这项开创性工作引发了持续20年的研究热潮。然而，到了1960年代，人工智能奠基人Minsky（明斯基）在《Perceptrons》中给出了致命一击：他证明即使是简单的“异或”（XOR）问题，两层神经网络也无法解决。这个结论犹如一盆冷水，导致整个神经网络领域陷入长达数十年的寒冬，连Hinton这样的杰出学者都因此难以找到工作。

这段历史给我们提出了一个深刻的问题，在看似绝望的理论限制下，是否存在工程突破的可能？这正是我们要探讨的第三原理的核心：如何突破理论限制，在工程层面实现广义学习机制。就像自然语言处理最终突破了传统语言学框架一样，我们是否也能找到深度学习的新范式？

4. 普适学习机制

原理3. 深度学习的充分性依据： Kolmogorov–Arnold 叠加

- Robert Hecht-Nielsen (HNC创始人), 1986-1987, 证明三层以上神经网络可以无限逼近任意连续函数。
- 希尔伯特第13问题, 数学根据是Kolmogorov 1956 年证明的Kolmogorov–Arnold 表示定理, 也称叠加定理或映射定理。



Kolmogorov's Mapping Neural Network Existence Theorem

Robert Hecht-Nielsen
Enrico Fermi Institute, University of Chicago
1987-1992, Director
1992-2001, President
1992-2001, CEO

Dedicated to Andrej Kardecic, Kolmogorov

Abstract

Kolmogorov's 1956 Theorem concerning the representation of a function of n variables by a sum of functions of one variable and n intermediate variables.

Notes

On 8/26, A.R. Kolmogorov published an astonishing theorem concerning the representation problem from the 1940s and earlier by the use of much smaller number of functions than the 1940s-1950s results. The theorem is stated in the following form:

Let $f(x_1, \dots, x_n)$ be a continuous function of n variables. Then there exist continuous functions $\phi_1, \dots, \phi_n$ of one variable and n intermediate functions $\psi_1, \dots, \psi_n$ of n variables such that

$$f(x_1, \dots, x_n) = \sum_{i=1}^n \phi_i(x_i) \psi_i(\psi_1, \dots, \psi_n)$$

where $\psi_1, \dots, \psi_n$ are functions of n variables. The result was a surprise to many mathematicians at the time.

Notes

A theorem was later proved and showing Kolmogorov's theorem is not always true. However, it is true for a large class of functions. This is the case for the case in neuroscience.



$$f(\mathbf{x}) = f(x_1, \dots, x_n) = \sum_{i=1}^n \Phi_i \left(\sum_{j=1}^n \phi_{ij}(x_j) \right)$$



这要归功于苏联数学家Kolmogorov (柯尔莫哥洛夫)。1955-1956年, 他为解决希尔伯特第13问题: 关于任意函数能否分解为简单函数叠加, 做出了突破性工作。当时希尔伯特猜想这是不可能的, 但Kolmogorov证明: 任何连续函数都能展开为简单函数的叠加。

有趣的是，这个数学成果与Minsky对神经网络的否定形成了鲜明对比。直到1986年，数学家出身的企业家Nielsen（尼尔森）在首届神经网络大会上发表了一篇4页的短文，指出Kolmogorov-Arnold叠加定理实际上推翻了Minsky的结论，只要神经网络达到三层以上，就能解决包括“异或”（XOR）在内的各种问题。

这直接催生了1987年提出的“通用逼近定理”(UAP)：只要神经网络足够深，就能逼近任意函数。这正是深度学习的理论基础。五六十年代的数学成果，在80年代推动了神经网络复兴，至今仍在启发新研究，比如去年MIT的KAN网络，基于Kolmogorov-Arnold理论。


正如物理学家Tegmark（马克斯·泰格马克）《生命3.0》作者的学生所做的工作所示，这些数学发现持续推动着AI发展。我想强调的是：50年代的数学突破，80年代催生了神经网络革命，至今仍在指引AI前沿研究。这正是第一性原理的力量：看似抽象的理论，最终塑造了技术发展的轨迹。

原理4：能耗与智能：Landauer Principle


Landauer Limit: 擦除一个信息位的最小能量: $2.9 \times 10^{-21} \text{ J}$

摩尔定律死了，摩尔定律万岁！

Moore's Law



Koomey's Law



摩尔定律修正：尼克定律: $y = \frac{ax}{(\ln(x))^{-a}} + b$

5. 计算与物理的关系


让我们回到最初那个半开玩笑的问题：“What is matter ? What is mind?”我们都知道算力需要消耗能量，但具体需要多少？

举个简单例子：把0变成1，或者1变成0，需要能量吗？需要多少能量？IBM物理学家Landauer（兰道尔）在1961年用热力学第二定律证明，至少需要 10^{-21} J ，具体数值与温度有关，可能在 10^{-23} J 量级。这个发现对工程实践有深远影响，它意味着 Moore's Law 终将遇到物理极限。


目前 Moore's Law（摩尔定律）已经放缓。虽然英伟达的老黄总说这两年加速了，但那只是 Scale out（横向拓展），真正的 Scale up（纵向提升）确实在减速。斯坦福土木工程系教授 Koomey（库米）提出的 Koomey's law（库米定律）指出：固定算力下，能耗会随时间下降。这本质上是 Moore's Law 的逆向表述。

最初 Moore's Law 预测性能每年翻倍，后来延长到18个月、24个月，现在需要3.5-4年才能翻倍。Koomey's law 同样面临瓶颈，能耗下降终将触及 Landauer 极限，即0到1转换所需的最小能量。Koomey 曾悲观预测2020-2040年间会触及这个极限，这意味着技术将无法继续进步。

但幸好 Moore's Law 放缓也延缓了这个进程。这个极限可能推迟到2080年左右才会触及。这说明，Mind 和 Matter 之间最直观的联系就是能量，就像 Planck constant（普朗克常量）限制了时空的无限可分性一样，Landauer 极限也划定了计算的物理边界。



大家都知道 Ilya 之前发动了一场未遂的“政变”，虽然把 Altman（奥特曼）短暂赶下台，但一周后自己反被驱逐。他团队最后离开的一位年轻成员在去年6月发表了一份题为《Situation Awareness》的报告，提出了一个关键问题：算力与能耗的关系。报告用 H100 显卡作为“硬通货”进行测算：2022年 GPT-4 训练需要1万张 H100，耗电10GW，相当于美国1万户家庭用电；到2024年这个数字将增长到10万张 H100 等价卡，耗电100GW；2026年预计需要100万张 H100 等价卡，耗电1000GW，相当于一个大型水电站；而到2030年，虽然可能只需2000万张下一代显卡，但耗电将高达1千兆GW，这相当于美国当前总电力的1/4。这个预测给我们敲响了警钟，虽然具体数字可能有争议，但 AI 发展带来的能源代价这个趋势确实值得我们深思。



我们从意识的探讨开始，最终落脚到物质的能源问题。当前地缘政治格局下，中国正大力发展核电，而美国则转向新型小型模块化反应堆（SMR）技术。四大科技巨头Microsoft、Amazon、Google和OpenAI都在推进这项技术。这形成了一个有趣的闭环：人工智能的发展最终把我们带回了核电议题。

历史总是惊人的相似：1979年三里岛核事故，早于切尔诺贝利，导致美国核电发展停滞，而去年微软收购了三里岛核电站，计划重启。新型SMR采用液态金属技术，理论上更安全可靠，这个话题我们后续可以深入探讨。

这让我想起一个关键问题：当技术发展触及物理极限时，我们该如何突破？就像Planck constant定义了量子世界的基础，能源技术也面临着类似的根本性挑战。

我的大师兄Sutton（萨顿）刚刚获得了图灵奖，这让我想起他和我的导师在研究方法上的分歧。Sutton在2019年发表了一篇博客《The Bitter Lesson》（苦涩的教训），这就是大学者的魅力所在，不需要发表在《Nature》这样的顶级期刊上，一篇博客就能成为经典。

Scaling Law 会失效吗？

- 摩尔定律失效，Koomey定律失效
- Scaling Law 必然会失效
- Koomey定律交到X轴，只能scale out不能scale up。Dennard Scaling失效后，过去15年，CPU主频没有得到实质提升。多核处理器的出现是受制于能耗的。x-纳米工艺没有意义。
- 并行计算的能耗要优于串行计算。Konopik, Lutz（2023）：理想的并行计算可以逼近兰道尔极限。

$$\frac{W_{\text{tot}}^{\text{par}}(N,T)}{N} = kT \ln 2 + \frac{a}{bT}$$

这篇博客的核心观点是什么？算法和数据都不重要，唯有算力才是关键。只要持续投入算力，终 will 实现AGI。这本质是对Scaling Law的绝对信仰。但正如我们讨论的，Scaling Law终将遭遇物理极限：Landauer极限， 10^{-23} J到 10^{-21} J是不可逾越的。就像Einstein所说，即便所有物理定律都失效，热力学第二定律永恒成立。

这引出一个根本矛盾：当算力发展触及Landauer极限时，Scaling Law还成立吗？如今工艺节点命名已失去意义，2nm实为营销术语，而《Nature》最新研究指出：未来必须依赖并行计算，因其能耗效率更优且更易逼近Landauer极限。

这让我想起80年代计算机学科的“鄙视链”：理论派与系统派互相轻视，却共同鄙视AI研究。如今局面完全逆转。AI学者已成为计算机系最有权势的群体。当年我的导师Barto（巴托）曾评价我“数学很好”，后来才明白这是委婉批评。

Sutton近期提出一个深刻观点：文本数据即将耗尽，视频数据也接近极限，未来出路可能是强化学习，因其能与环境持续交互。一个值得探讨的问题是：能否用数学证明强化学习可实现Solomonoff归纳，即图灵机求逆？若成立，则强化学习就是最广义学习机制。

这揭示了一个永恒辩证关系：工程实践需要理论指引，而理论突破也需要工程验证。正如Landauer极限警示我们：技术发展终将面对物理边界，但在此之前，理论与工程的协同创新仍大有可为。



我这张图完整展现了强化学习的传承脉络。我提出了一个关键问题：强化学习能否实现Solomonoff归纳？如果能，这张图就完整勾勒出了我们这一支的学术谱系。要知道，人工智能有三大流派：第一支是逻辑学派，第二支是神经网络学派，第三支就是我们强化学习这一支。我们的学术渊源可以追溯到进化论，也可以追溯到John von Neumann（冯·诺伊曼）。

John von Neumann开创了细胞自动机，他的助手Burks（伯克斯）继续研究细胞自动机，而Burks的学生Holland（霍兰德）发明了遗传算法。Holland还提出了一个如今随处可见的概念：“涌现（Emergence）”。Holland正是 Barto（巴托）的导师。

6.回到第一性原理

让我们回到第一性原理的讨论。达特茅斯会议的启示在于：有些看似数学的理论实则不然，有些看似物理的命题也非表面所见。当年参会的Shannon（香农）、McCarthy（麦卡锡）等人都很年轻，最大的Shannon不过35岁。而50年后，2006年他们重聚合影时，最右边的Solomonoff尚在世，他于2009年去世。

这给我们一个重要启示：理论与工程的发展往往不同步。在大模型领域，理论上过于超前。McCarthy在1954年提出的问题，Solomonoff在1964年就给出了证明，1965年又证明了Kolmogorov复杂度与Solomonoff归纳的等价性。这些理论成果直到2023年8月14日Ilya的演讲才被完全确认。

Ilya这个俄罗斯移民虽然英语不流利，却被很多人奉若神明。毕竟年轻的“先知”更有魅力。他自称2016年独立想到了Solomonoff归纳，这个说法真伪难辨。若有朝一日能当面求证，我一定要详细追问：这究竟是他自己的创见，还是早已知晓的理论？

总结：机器能思考吗？回顾人工智能：1956-2024

● 第一原理：所有计算都是图灵机 (Church-Turing)

● 第二原理：所有学习都是所罗门诺夫归纳

● 第三原理：存在实现学习的普适机制 (例如神经网络)

● 第四原理：计算需要能量，能量被 Landauer 极限所约束。

● 达特茅斯会议建议书中的问题

- 1. Automatic Computers
- 2. How Can a Computer be Programmed to Use a Language
- 3. Neuron Nets
- 4. Theory of the Size of a Calculation
- 5. Self-improvement
- 6. Abstractions
- 7. Randomness and Creativity

● 新问题

- 可解释性与安全性 (司法, 驾驶, 诊断)
- 伦理、道德、法律
- 意识 (伪问题?)

正是工程实践往往领先于理论的原因。达特茅斯会议1956年提出的7个核心问题，至今每个都仍有大量工作待完成，甚至还衍生出新的挑战。但不可否认，人工智能已经在工程应用层面取得了实质性突破。

随着AI技术的快速发展，可解释性、安全性、道德、法律、伦理等新问题接踵而至。1956年的那些技术问题尚未完全解决，但方向已经明确。就像Newton提出4条原理一样，我今天也提出4条原理，旨在为达特茅斯会议提出的根本问题提供思考框架。这些原理本身不一定能直接解决问题，但希望能为科学家和工程师提供新的思路 and 方向。

最后，我来总结下这四条第一性原理：

第一，计算本质：图灵机是否定义了最广义的计算装置？这个问题我们今天已经深入探讨。

第二，学习机制：是否存在通用的学习理论？数学上的Solomonoff归纳和工程上的大模型发展都给出了肯定答案。

第三，工程实现：能否找到普适的技术路径？就像神经网络突破理论限制那样，我们需要持续探索。

第四，物理边界：意识与物质如何联系？Landauer极限给出了计算的能耗下限。

这些原理不是最终答案，而是思考的起点。就像Newton的四大原理指引了物理学发展一样，希望这些原理能为AI领域的探索提供方向。

最后感谢各位的聆听与思考。

【系列课程专题】：<https://www.chaspark.com/#/s/principia?multi=zh>

12/12